

论文研读报告

摘要

本文选取 ACL 2020 中的一篇文章 [*Modelling Context and Syntactical Features for Aspect-based Sentiment Analysis*](#) (Phan & Ogunbona, ACL 2020) 进行阅读，并主要针对其研究任务、研究方法、创新点与实验结果进行分析总结汇报。最终进行个人感悟总结。

关键词： ACL 2020、[*Modelling Context and Syntactical Features for Aspect-based Sentiment Analysis*](#) (Phan & Ogunbona, ACL 2020)、论文研读报告

内容目录

1 引言	3
1.1 问题背景.....	3
1.2 论文背景及创新点.....	3
2 论文阅读.....	3
2.1 研究方法汇报.....	3
2.2 实验结果分析汇报.....	6
3 个人感悟总结.....	8

1 引言

1.1 问题背景

情感分析是文本分类任务的一种，情感分类的主要方法是提取文本特征，并基于这些特征进行分类。根据其研究对象的粒度不同，可分为文本级、句子级、对象级等。其中，较细粒度的情感分析为对象级情感分析（Aspect-level Sentiment Analysis, ASA），具体任务为对一段文本和指定的待分析对象，判断出为针对该对象的情感倾向进行分类。

而一句话中可能包含多方面（对象）的情感，以某评论“这条裤子的材质很好，但是拉链太差了”为例，从 **fine-grained**（细粒度）评价角度来说，该买家对商品的“材质”这一 **aspect** 的评价为 **Positive**，而对“拉链”这一 **aspect** 评价为 **Negative**，但 **aspect** 和对应的情感是隐式地体现在评价中，需要我们利用模型抽取出来。

方面级情感分析（Aspect-based sentiment analysis, ABSA）主要包括方面词抽取和方面级情感分类。ABSA 任务需要识别出给定目标中特定方面的情感极性，通常可分为两个子任务：方面类型情感分析和方面词项情感分析。任务难点在于：文本中表示情感判断的词汇与对应方面的关系是不确定的。一方面，需要挖掘语意特征和句法结构特征，正确提取与指定对象相关的情感词汇，排除其他情感词汇的干扰；另一方面，情感分析在应用中要求工具能解释做出判断的依据，这对模型的可解释性提出了要求。

1.2 论文背景及创新点

所选论文中，学者们认为既有的研究大都将两个子任务分离开独立进行研究，这会造成方面提取模型无法充分利用句法信息的重要性，从而无法检测多词方面术语的边界，体态情感分类器无法解释体态词和语境词之间的句法相关性。

为了解决该问题，所选论文构建了一种端到端的对象级情感分析方法，可以充分利用语法信息，使用自注意力机制进行句法学习，充分挖掘句法结构，并将句法信息整合到上下文表示中，具体操作为使用 **part-of-speech** 表示、依存表示和上下文嵌入（如 **BERT**，**RoBERTa**）；提出句法相对距离，来降低非相关单词的影响力。最终建立了一个能充分利用上下文和句法信息的一体化工具，有效地提升了对对象级情感分类成绩。

2 论文阅读

2.1 研究方法汇报

所选论文的研究方法主要包括两个核心单元：

(1) 对象抽取（AE）单元

学者们将结合语法信息的 AE 任务称为 CSAE（contextualized syntax-based AE），“基于句法的结构化对象抽取器”，并创新型的结合了预训练语言模型。

该单元的主要目标是标识句中每一个单词是否属于对象词汇，该单元框架如下图所示：

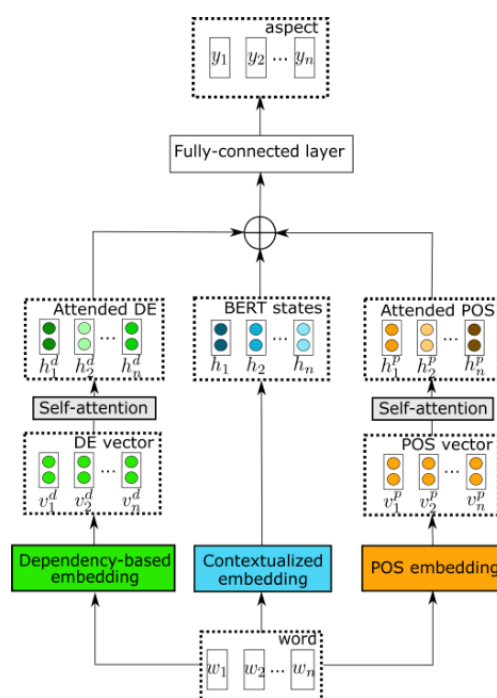


图 1 AE 单元框架

下面介绍该单元的具体方法流程：

➤ 利用词法信息

学者们参考 *Universal POS tags* (<https://universaldependencies.org/u/pos/>)

利用已有工具获取 POS 词性标签序列，之后通过一个嵌入矩阵将词性转化为向量，对词性之间的依赖关系进行建模。之后通过自注意力层抽取整个句子的语法依存关系。依存表示模块使用了基于句法关系的依存表示，首先要对每个目标词汇及其修饰词建立上下文集合，随后的依存关系学习可以延伸到距离较远的上下文，还能将不相关词汇（即使距离很近）的重要性降低。

➤ 利用句法信息

学者们参考了 *Omer Levy and Yoav Goldberg. 2014. Dependencybased word embeddings. In Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), pages 302–308. (<https://www.aclweb.org/anthology/P14-2050/>)*

在 skip-gram 模型中，单词被用来预测上下文，而上下文是通过一个窗口确定的；因此学者们认为应该根据句法关系来确定上下文，并将这种上下文称为 **Dependency-Based Contexts**(基于依赖关系的上下文)。具体而言，首先对给定句子进行句法解析，得到句法解析树，然后将其中的介词和关系进行合并，于是一个单词的 **Dependency-Based Contexts** 即为在树中该词的相邻节点和关系，下图为基于依赖关系的上下文示例：




图 2 Dependency-based context 示例

(2) 对象级情感分析 (ASC) 单元

该单元参考了 *Biqing Zeng, Heng Yang, Ruyang Xu, Wu Zhou, and Xuli Han. 2019. Lcf: A local context focus mechanism for aspect-based sentiment classification. (https://www.researchgate.net/publication/335238076_LCF_A_Local_Context_Focus_Mechanism_for_Aspect-Based_Sentiment_Classification)* 所提出的 LCF-ASC 模型。挖掘局部上下文注意力信息，将上文得到的上下文表示和对象术语转换为情感分类标签，具体思路是降低相关性较小的信息的权重。

该单元的框架图如下所示：




图 3 ASC 单元框架

该单元主要有两个组成部分：local context 局部上下文特征与 global context 全局上下文特征；不妨记句子为 S ，属性词为 A ，则称 $[CLS] + S + [SEP]$ 为 local context，而称 $[CLS] + S + [SEP] + A + [SEP]$ 为 global context。

而为了在 local context 引入属性词的信息，LCF-BERT 提出了两种方法（CDM/CDW）进行 Local Context Focus(LCF)。

CDM 即为 context dynamic mask，是指根据与属性词之间的距离来屏蔽句子中的一些单词；而完全屏蔽某些单词可能过于绝对，所以提出了 CDW。

CDW 即为 context dynamic weighting，是按照与属性词之间的距离为单词赋予一个 0 到 1 之间的权重。

学者们基于 LCF-ASC 提出了 LCFS-ASC 模型，即 local context focus on syntax - ASC，与 LCF-BERT 的不同之处在于：在进行 CDM/CDW 时所使用的单词之间的距离，不再是通过位置计算，而是两个单词在句法解析树中的距离（句法相对距离）。学者们认为 CDW 比 CDM 更有助于提高 LCFS-ASC 模型的性能。由于 CDM 完全屏蔽了被识别为不重要的上下文的信号，它可能会错误地忽略有用的信号。另一方面，CDW 强调灵活性，并允许进一步的信号贡献与其与基于依赖关系的树中的方面项的相关性相对应的小权重

具体做法为通过将局部上下文向量送入上下文特征权重动态遮罩工具和动态调整工具，分别可以调整距离对象较远的词汇的权重（去除和降低）：在特征权重动态遮罩工具中，若当前词的相对距离大于预设的阈值，重要性矩阵对应该词的一列为，否则该列为，即全 0 或全 1 向量；在特征权重动态调整工具中，若当前词的相对距离大于预设的阈值，重要性矩阵对应该词的一列为 1；否则，该列为 0。

2.2 实验结果分析汇报

➤ AE

学者们仅在 semeval-14 的 ABSA 数据集上进行了实验。数据集总体展示如下图所示：

Dataset	Training			Testing		
	Pos	Neg	Neu	Pos	Neg	Neu
Restaurant	1315	462	368	426	143	146
Laptop	602	514	260	201	197	94

图 4 训练和测试数据中按极性划分的实例数

实验结果及对比如下图所示：

	Domain	Laptop	Rest
	Model	F1	F1
Single-task	BiLSTM	73.72	81.42
	DTBCSNN	75.66	83.97
	BERT-AE	73.92	82.56
Integrated	MNN	76.94	83.05
	UABSA	77.34	83.92
	IMN	77.96	83.33
Proposed	RoBERTa-AE	75.22	85.12
	RoBERTa-POS	76.01	85.56
	RoBERTa-Dep	76.88	86.25
	CSAE	77.65	86.65

Note: The best result in each dataset is highlighted in bold

图 5 表现最佳 AE 模型变量 F1 分数 (%) 与最新方法的比较

可以看到，在使用了词法信息和句法信息后，F1 值有了较大的提升（CSAE>RoBERTa-AE），而句法信息带来的提升更加明显（RoBERTa-Dep>RoBERTa-POS）。

➤ ASC

实验结果及对比如下图所示：

Domain	Laptop		Rest	
Model	F1	Acc	F1	Acc
AOA	-	74.5	-	81.2
MGAN	72.47	75.39	71.94	81.25
BERT-ASC *	72.68	76.25	76.98	84.46
BERT-PT	75.08	78.07	76.96	84.95
AEN-BERT	76.31	79.93	73.76	83.12
LCF-BERT-CDW *	76.20	80.21	79.12	85.91
LCF-BERT-CDM *	75.76	79.65	78.74	85.73
MNN	65.98	70.40	68.45	77.17
UABSA	68.24	72.30	68.38	79.68
IMN	72.02	75.36	75.66	83.89
RoBERTa-ASC	70.52	74.12	75.12	82.82
LCFS-ASC-CDW	77.13	80.52	80.31	86.71
LCFS-ASC-CDM	76.45	80.34	80.10	86.13

Note: The best result in each dataset is highlighted in bold.

The results of models we reproduced by following the methodology published in the paper are indicated by asterisk (*).

图 6 表现最佳的 ASC 模型变量的 F1 分数和准确率 (%) 与最先进的方法的比较

可以看到，使用了 LCFS 的策略之后，模型性能有了很大的提高，并且 CDW 优于 CDM；LCFS 稍微优于 LCF。并且在没有使用外部词库的条件下，该模型均取得了较佳效果，证明本文的设想的确有足够的合理性。

➤ 结果综述

所选论文提出了一种端到端的 ABSA 解决方案，该解决方案通过管道将方面提取器和方面情感分类器连接起来。实验结果表明，利用句子的句法结构可以使语境化模型在 ASC 和 AE 任务中改进现有的工作。其提出的方面情感分类器优于训练后的 ASC 模型，能够创建一个独立于领域的解决方

案。所提出的 SRD 允许方面情绪分类器关注关键情绪词，这些词通过基于依赖关系的结构修改目标方面词。这些实质性的改进突出了最近语境化嵌入模型在“理解”句法特征方面的不足，并提出了开发更多语法学习语境化嵌入的未来方向。后续可以尝试通过应用统一的标记方案来调整我们提出的 CSAE 体系结构，以实现集成方法；达到可以同时实现方面提取和情感分类的目的效果。

3 个人感悟总结

这是我首次撰写论文研读报告，受益匪浅。在阅读完本次所选论文后，我对情感分类的任务有了更深层次的理解，并且学到了新的相关知识，按条理逻辑撰写阅读报告，对论文的理解与梳理帮助很大并且逻辑性强。所选论文也是基于已有研究进行思考创新，这让我意识到论文阅读与思考的重要性。

但对于实际实践操作尚存在困难与问题，未来的日子中，我将继续阅读相关文献，接触前沿信息科技，努力将所学内容与实践相结合。